Instituto Tecnológico y de Estudios Superiores de Monterrey

Analítica de Datos y

Herramientas de Inteligencia Artificial

Reporte de actividad 1.2 avance

Profesor**:** Alfredo apellido apellido

Camila Trujillo Beristain | A01737170

Bernardo Quintana López | A01658064

Fernando Guadarrama González | A01379340

Mauricio Goris García | A01736428

Campus Puebla

30 de marzo de 2025

Reporte Explicativo del Análisis de Datos

Este análisis es del código con proceso completo de análisis de datos, desde la carga y limpieza hasta la visualización, detección de valores atípicos, etc.

El código comienza con la instalación de paquetes necesarios: Estos paquetes proporcionan herramientas para el análisis exploratorio de datos (funpymodeling) y para trabajar con archivos Excel (openpyxl).

```
%pip install funpymodeling
%pip install openpyxl
```
✓ 2.9s Python

Después se importan las bibliotecas esenciales para el análisis y la carga de los datos por el archivo csv, se realiza la exploración de datos, y la búsqueda de valores nulos por columna.

```
#Buscamos valores nulos y calculamos porcentajes por columna
valores_nulos1 = data.isnull().sum()
print(valores_nulos1)
```
[ ]

Execute Cell (^Enter)

```
Administrador              0
Usuario                    0
botón correcto           762
tiempo de interacción    762
mini juego               156
número de interacción    762
color presionado         762
dificultad                 0
fecha                      0
Juego                      0
auto push                762
tiempo de lección        177
tiempo de sesión         606
dtype: int64
```

Esto indica que varias columnas tienen valores nulos, especialmente "botón correcto", "tiempo de interacción", "número de interacción", "color presionado" y "auto push" con 762 valores nulos cada una.

Se verifican los tipos de datos de cada columna y separamos las variables por numéricas y categóricas: para las variables numéricas generales (excluyendo "tiempo de sesión" y "tiempo de lección"), se reemplazan los valores nulos con la media y para "tiempo de sesión" y "tiempo de lección", se calcula la media excluyendo ceros y luego se reemplazan los nulos:

media_sesion_sin_ceros = tiempo_sesion.mean()
media_leccion_sin_ceros = tiempo_leccion.mean()

tiempo_sesion_sin_nulos = tiempo_sesion.fillna(media_sesion_sin_ceros)
tiempo_leccion_sin_nulos = tiempo_leccion.fillna(media_leccion_sin_ceros)

Posterior a eso, para la visualización de los datos se crea un diagrama de caja para identificar valores atípicos:

```
fig = plt.figure(figsize = (15,10))
numericas_generales_sin_nulos.plot(kind='box', vert=False)
plt.xlim([0, 600])
plt.title('Valores Atípicos de DataFrame')
plt.yticks(fontsize=7, rotation=0)
plt.show()
```

```
<Figure size 1500x1000 with 0 Axes>
```

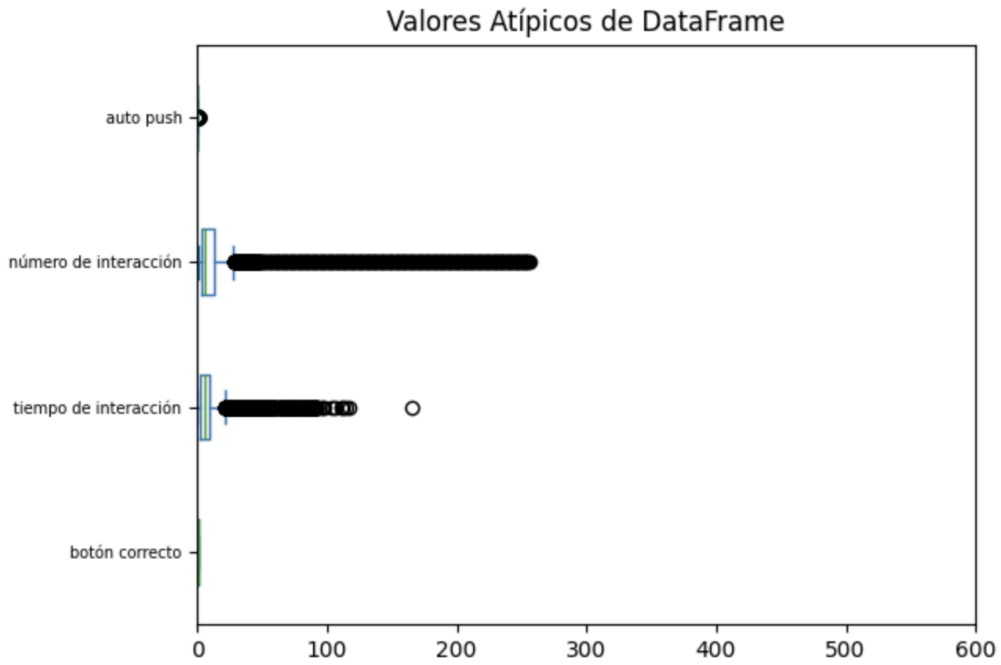

Después de que el diagrama de caja horizontal mostrara valores atipicos, se hace una detección y manejo de ellos, donde se calculan los límites para valores atípicos usando el rango intercuartílico (IQR):

```
y=numericas_generales_sin_nulos

percentile25=y.quantile(0.25) #Q1
percentile75=y.quantile(0.75) #Q3
iqr= percentile75 - percentile25

Limite_Superior_iqr= percentile75 + 1.5*iqr
Limite_Inferior_iqr= percentile25 - 1.5*iqr
print("Limite superior permitido", Limite_Superior_iqr)
print("Limite inferior permitido", Limite_Inferior_iqr)
```

```
Limite superior permitido botón correcto           2.50000
tiempo de interacción    21.81771
número de interacción    28.84852
auto push                 0.00000
dtype: float64
Limite inferior permitido botón correcto          -1.500000
tiempo de interacción    -9.731186
número de interacción   -12.509112
auto push                 0.000000
dtype: float64
```

Después se realizó un proceso de limpieza de datos en Python donde primero se filtraron outliers, luego se detectaron valores nulos (669 en "tiempo de interacción", 371 en "número de interacción" y 816 en "auto push") usando isnull().sum(), y finalmente se creó una copia del dataframe rellenando los nulos con la media redondeada de cada columna, evidenciando errores tipográficos como "isnu1" y "filing" en lugar de las funciones correctas, pero demostrando claramente el flujo típico de limpieza: filtrar, analizar nulos e imputar valores.

Posterior motramos los atípicos de dataframe en las columnas numéricas, graficando con el diagrama de caja, y mostrando la distribución de los datos y sus valores extremos.

```
fig = plt.figure(figsize = (15,10))
numericas_con0.plot(kind='box', vert=False)
plt.xlim([0, 600])
plt.title('Valores Atípicos de DataFrame')
plt.yticks(fontsize=7, rotation=0)
plt.show()
```

```
<Figure size 1500x1000 with 0 Axes>
```

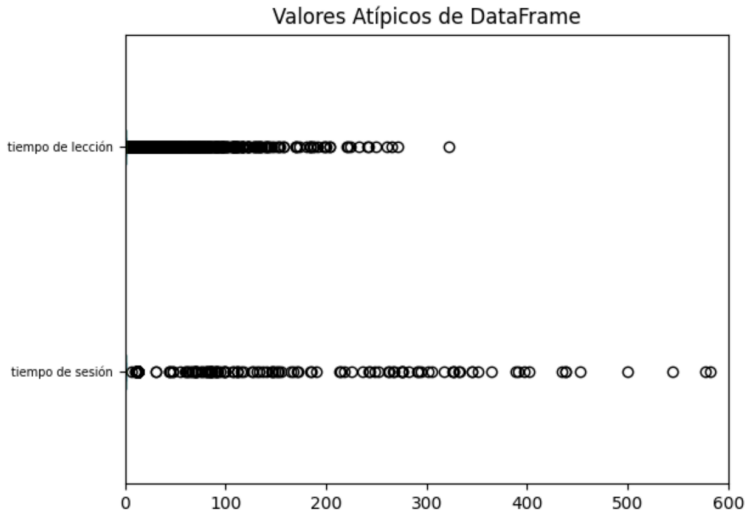

De ahí se realizó un análisis de datos para las variables "tiempo de sesión" y "tiempo de lección", calculando los percentiles 1% y 99% para identificar valores atípicos. Se intentó filtrar los datos conservando solo los valores dentro de estos límites (0.0 como mínimo y 296.97/118.95 como máximo). Para terminar detectando 59 valores nulos en cada columna del filtrado.

```
[ ]  valores_nulos3=data4_iqr.isnull().sum()
     valores_nulos3
```

```
...  tiempo de sesión     59
     tiempo de lección    59
     dtype: int64
```

Posterior se hacen operaciones de manipulación de datos con pandas, incluyendo la copia de un DataFrame combinado (data3_igredata4_igr), el relleno de valores nulos con la media

redondeada de otro conjunto de datos (data4_igr), y la visualización de las primeras filas de data3_igr, donde todas las columnas ("tiempo de sesión" y "tiempo de lección") aparecen con valores 0.0. Luego, verificamos la ausencia de valores nulos y finalmente se concatenan tres DataFrames: uno cualitativo con valores nulos reemplazados por "Sin Dato" y dos copias de data3_igr.

```
[ ]  valores_nulos4=data5_iqr.isnull().sum()
     valores_nulos4
```

```
tiempo de sesión     0
tiempo de lección    0
dtype: int64
```

Posterior confirmamos si los nulos se han ido correctamente, y efectivamente ya no había ni uno:

```
valores_nulos5=data_final.isnull().sum()
valores_nulos5
```

```
Administrador            0
Usuario                  0
mini juego               0
color presionado         0
dificultad               0
fecha                    0
Juego                    0
botón correcto           0
tiempo de interacción    0
número de interacción    0
auto push                0
tiempo de sesión         0
tiempo de lección        0
dtype: int64
```

Después generamos una tabla de frecuencias a partir de datos agrupados por la columna 'Administrador'. Primero, creamos la tabla (table1), luego eliminamos las columnas de porcentajes (table2), y finalmente establecimos 'Administrador' como índice (Filtration). El resultado es una lista de administradores con sus respectivas frecuencias (conteos de apariciones), donde "ALEDA" tiene la mayor frecuencia (3260) y "BENJAMIN" la menor (51), mostrando los datos ordenados de mayor a menor frecuencia.

De ahí, se generó un gráfico de barras a partir de un DataFrame o Serie de pandas llamado Filtro_index1, mostrando la frecuencia (cantidad de ocurrencias) de distintos administradores.Aquí está el desglose:

```
Filtro_index1.plot(kind = 'bar', width=0.8, figsize=(10,4), color='firebrick')
plt.title('Administrador')
plt.xlabel('Nombre de administrador')
plt.ylabel('Frecuencia')
```

```
Text(0, 0.5, 'Frecuencia')
```

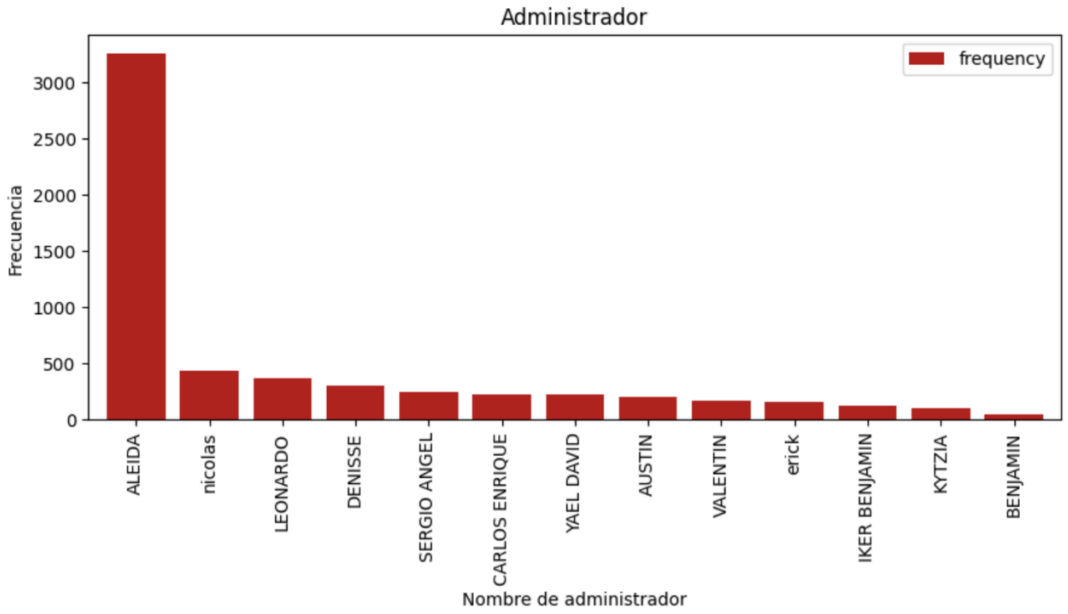

El gráfico muestra la distribución de administradores, donde cada barra corresponde a un nombre y su altura refleja su frecuencia.

Se creó un gráfico de barras a partir del DataFrame Filtro_index2 usando matplotlib, configurando barras de color coral con un ancho de 0.8 y un tamaño de figura de 10x4 pulgadas.

```
Filtro_index2.plot(kind = 'bar', width=0.8, figsize=(10,4), color='coral')
plt.title('Usuario')
plt.xlabel('Nombre de usuario')
plt.ylabel('Frecuencia')
```

```
Text(0, 0.5, 'Frecuencia')
```

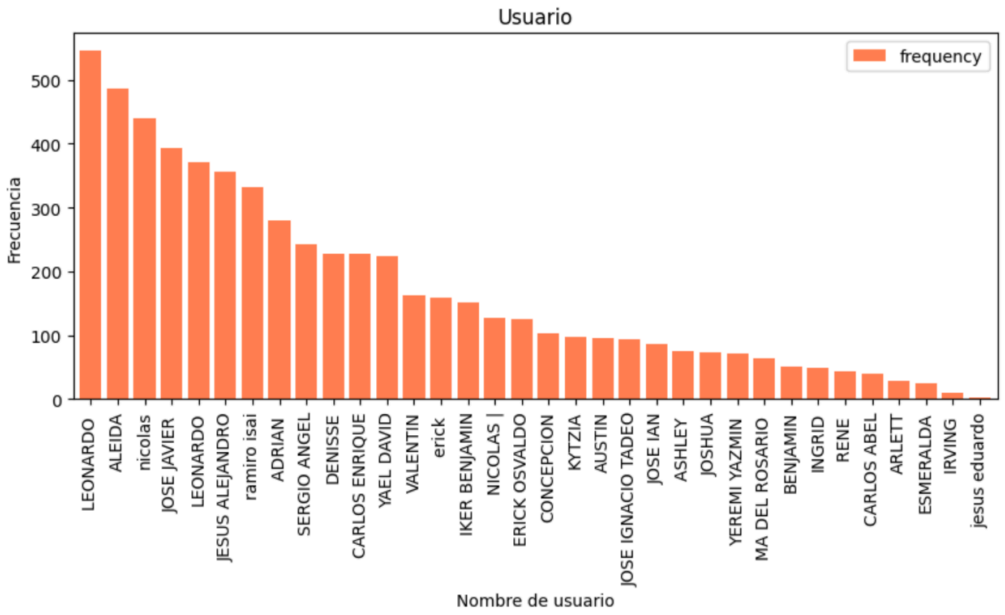

El gráfico muestra la frecuencia de cada usuario, con el título "Usuario", el eje X etiquetado como "Nombre de usuario" y el eje Y como "Frecuencia", proporcionando una visualización clara de la distribución de datos.

Posterior se creó un gráfico que muestra un diagrama de áreas apiladas en tono naranja oscuro semitransparente, representando la frecuencia de uso de distintos mini-juegos (como "Asteroides" y "MiniGame_0") en un rango de 0 a 1000. El eje X etiqueta los nombres de los juegos.

Categorización de la Variable "Tiempo de Interacción"

Para facilitar el análisis e interpretación de los datos, realizamos una categorización de la variable cuantitativa "tiempo de interacción". Este procedimiento nos permite agrupar los datos numéricos en intervalos definidos, transformándolos en una variable categórica más fácil de estudiar mediante frecuencias o gráficos.

1. Cálculo de valores mínimos y máximos

Primero, identificamos los valores extremos de la variable:

```
Max=data_final['tiempo de interacción'].max()
Min=data_final['tiempo de interacción'].min()
Limites= [Min, Max]
Limites
```

[1642] Python

```
[0.0, 21.78444]
```

Esta etapa es fundamental para asegurarnos de que todos los valores estén contemplados dentro de los intervalos que se construirán más adelante.

2. Definición de intervalos y categorías

Una vez conocidos los límites, establecimos los intervalos de tiempo que permitirían clasificar los datos en distintos niveles de interacción. Estos intervalos no fueron generados automáticamente, sino definidos manualmente con base en criterios prácticos, lo que permitió asignar etiquetas significativas.

```
intervalos=np.linspace(0.0000, 21.78444, 4)
intervalos
```

546] Python

```
array([ 0.     ,  7.26148, 14.52296, 21.78444])
```

```
#Creamos las categorías
categorias= ["Bajo 0-7", "Medio 7-14", "Alto 14-21"]
```

547] Python

3. Transformación de la variable numérica en categórica

Con los intervalos y etiquetas definidos, procedimos a aplicar la función pd.cut() de la librería pandas, que permite convertir una columna numérica en una categórica con base en los rangos establecidos:

```
#Finalmente creamos las categorías en la columna numérica
data_final['tiempo de interacción']=pd.cut(x= data_final['tiempo de interacción'], bins=intervalos, labels=cat
data_final['tiempo de interacción']
```

1648] Python

```
5723    Medio 7-14
5724    Medio 7-14
5725    Medio 7-14
5726      Bajo 0-7
5727      Bajo 0-7
5728      Bajo 0-7
5729      Bajo 0-7
5730    Medio 7-14
5731    Medio 7-14
5732      Bajo 0-7
5733      Bajo 0-7
5734      Bajo 0-7
5735      Bajo 0-7
5736    Medio 7-14
5737    Medio 7-14
```

Este paso realiza automáticamente la asignación de etiquetas a cada fila del dataset, dependiendo del valor que tenga en la variable "tiempo de interacción". De este modo, cada usuario quedó clasificado en uno de los cinco niveles definidos.

4. Conteo de frecuencias por categoría

Finalmente, para analizar la distribución de los datos resultantes, calculamos la cantidad de observaciones que pertenecen a cada categoría:

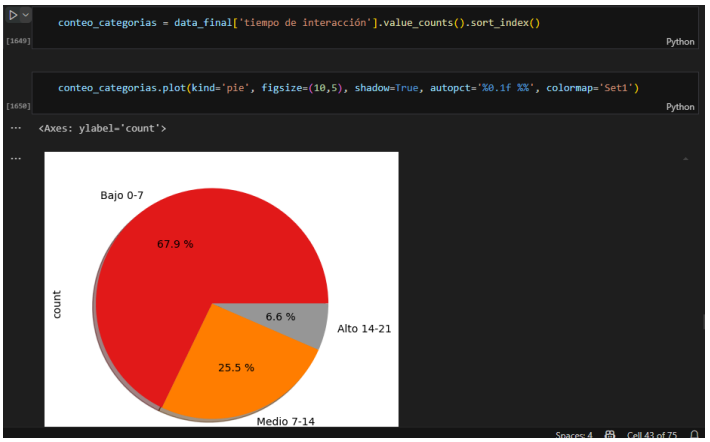

Este conteo nos permite visualizar cuántos usuarios se ubican en cada nivel de interacción, lo que a su vez ofrece una visión más clara del comportamiento general de los usuarios dentro de la plataforma educativa.

Este proceso de categorización no sólo mejora la comprensión del fenómeno estudiado, sino que también nos facilita la creación de visualizaciones más claras, como gráficos de barras o pastel, que permiten comunicar los resultados a audiencias no técnicas.

Categorización de la Variable "Tiempo de Lección”

Al igual que con el tiempo de interacción, la variable tiempo de lección representa una medición continua que indica cuánto tiempo dedicaron los usuarios a estudiar o completar lecciones dentro de la plataforma. Para facilitar su análisis y comparación entre diferentes grupos de usuarios, esta variable fue transformada en una variable categórica mediante un proceso de clasificación por intervalos.

1. Identificación del rango de valores

Primero se determinaron los valores extremos (mínimo y máximo) de la variable, con el fin de comprender la dispersión de los datos y definir límites adecuados para los intervalos:

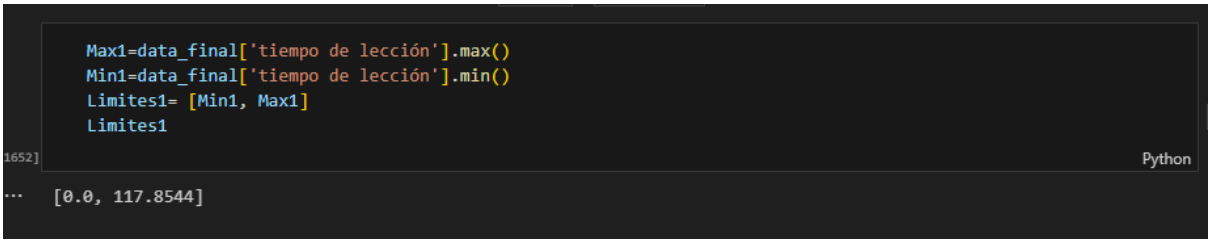

Esto permitió obtener una visión clara de los valores más bajos y más altos registrados por los usuarios en esta dimensión.

2. Establecimiento de intervalos y categorías

Después, se definieron manualmente los intervalos que agrupan el tiempo de lección en diferentes niveles. A cada intervalo se le asignó una etiqueta representativa que facilita la interpretación:

```
[1656]
intervalos1 = np.linspace(-0.1, 117.8544, 4)
np.set_printoptions(suppress=True)
intervalos1
Python

array([ -0.1       ,  39.21813333,  78.53626667, 117.8544    ])

#Creamos las categorías
categorias1 = ["Bajo 0-39", "Medio 39-78", "Alto 78-118"]
[ ]
Python
```

Estas categorías permiten resumir el comportamiento de los usuarios respecto a su tiempo dedicado al estudio de lecciones.

3. Transformación de datos numéricos a categorías

Utilizando `pd.cut()`, se asignaron las etiquetas correspondientes a cada observación del conjunto de datos:

```
#Finalmente creamos las categorías en la columna numérica
data_final['tiempo de lección']=pd.cut(x= data_final['tiempo de lección'], bins=intervalos1, labels=categorias
data_final['tiempo de lección']
[1658]
Python

5671     Bajo 0-39
5672     Bajo 0-39
5673     Bajo 0-39
5674    Alto 78-118
5675     Bajo 0-39
5676     Bajo 0-39
5677     Bajo 0-39
5678     Bajo 0-39
5679     Bajo 0-39
5680     Bajo 0-39
5681     Bajo 0-39
5682     Bajo 0-39
5683    Alto 78-118
5684     Bajo 0-39
5685     Bajo 0-39
5686     Bajo 0-39
5687     Bajo 0-39
5688     Bajo 0-39
5689     Bajo 0-39
5690    Alto 78-118
5691     Bajo 0-39
5692     Bajo 0-39
```

Esta transformación convierte los valores numéricos continuos en una variable categórica, facilitando su análisis a través de frecuencias o gráficos.

4. Análisis de la distribución por categoría

Finalmente, se contó cuántos usuarios quedaron en cada categoría de tiempo de lección:

```
conteo_categorias1 = data_final['tiempo de lección'].value_counts().sort_index()
```
[1659] Python

```
conteo_categorias1.plot(kind='pie', figsize=(10,5), shadow=True, autopct='%0.1f %%', colormap='Set2')
```
[1660] Python

```
<Axes: ylabel='count'>
```

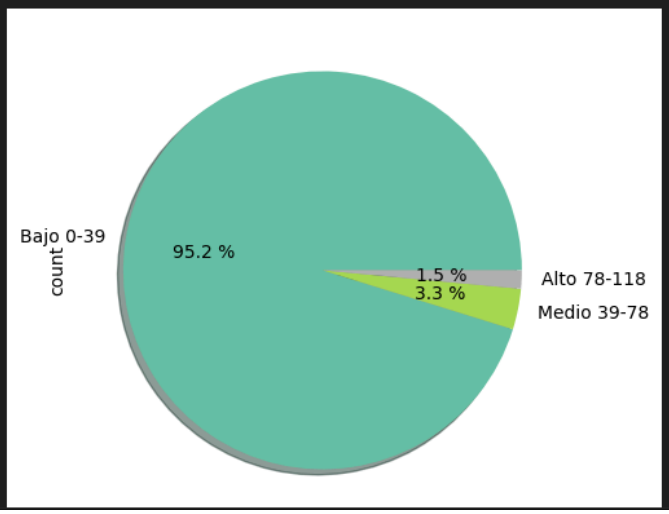

Esto permitió identificar qué tan común era cada nivel de dedicación y hacer comparaciones entre los grupos.

Categorización de la Variable "Tiempo de Sesión”

La variable tiempo de sesión refleja el tiempo total que un usuario permanece conectado en la plataforma. Esta métrica también fue categorizada para facilitar su interpretación, siguiendo el mismo procedimiento que en los casos anteriores.

1. Obtención de valores extremos

Se calcularon los valores mínimo y máximo de esta variable para determinar el rango total de tiempos registrados:

```
Max2=data_final['tiempo de sesión'].max()
Min2=data_final['tiempo de sesión'].min()
Limites2= [Min2, Max2]
Limites2
```
[1662] Python

```
[0.0, 294.3935]
```

Esto nos permitió tener una base sólida para definir los intervalos de categorización.

2. Definición de intervalos y etiquetas

Al igual que en los casos anteriores, agrupamos los datos en cinco categorías, definidas de forma manual para reflejar distintos niveles de uso de la plataforma:

```
intervalos3 = np.linspace(-0.1, 294.3935, 4)
np.set_printoptions(suppress=True)
intervalos3
```
[1666] Python

```
array([ -0.1   ,  98.0645, 196.229 , 294.3935])
```

```
#Creamos las categorías
categorias3= ["Bajo 0-98", "Medio 98-196", "Alto 196-294"]
```
[1667] Python

+ Code + Markdown

3. Conversión de variable continua a categórica

Utilizamos la función `pd.cut()` para asignar a cada observación una categoría específica según el intervalo en el que se encontraba:

```
#Finalmente creamos las categorías en la columna numérica
data_final['tiempo de sesión']=pd.cut(x= data_final['tiempo de sesión'], bins=intervalos3, labels=categorias3
data_final['tiempo de sesión']
```
[1668] Python

```
5779      Bajo 0-98
5780      Bajo 0-98
5781      Bajo 0-98
5782      Bajo 0-98
5783      Bajo 0-98
5784      Bajo 0-98
5785      Bajo 0-98
5786      Bajo 0-98
5787      Bajo 0-98
5788      Bajo 0-98
5789      Bajo 0-98
5790      Bajo 0-98
5791      Bajo 0-98
5792      Bajo 0-98
5793      Bajo 0-98
5794      Bajo 0-98
5795      Bajo 0-98
5796      Bajo 0-98
5797      Bajo 0-98
5798      Bajo 0-98
5799      Bajo 0-98
5800      Bajo 0-98
```

4. Conteo de frecuencias de las categorías

Finalmente, analizamos la distribución de los datos por categoría para comprender mejor el comportamiento general de los usuarios:

```
conteo_categorias2 = data_final['tiempo de sesión'].value_counts().sort_index()
```
[1670] Python

```
conteo_categorias2.plot(kind='pie', figsize=(12,6), shadow=True, autopct='%0.1f %%', colormap='Set3', textprop
```
[1678] Python

```
<Axes: ylabel='count'>
```

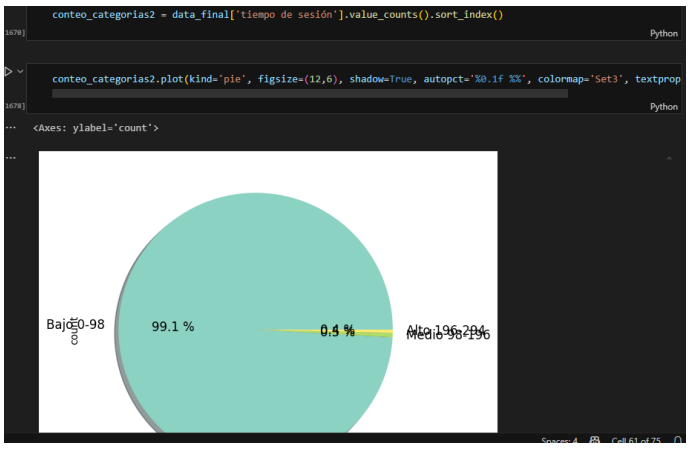

Este análisis nos resultó útil para identificar los patrones de permanencia dentro de la plataforma, revelando qué tan comprometidos están los usuarios en términos de tiempo de conexión.